目录

第一章 引论 **1**

1.1 信息检索的定义 1

1.2 信息检索的起源与发展 2

1.2.1 信息检索的起源 2

1.2.2 信息检索的发展历史 3

1.3 信息检索的两个任务 4

1.3.1 信息的序化组织 5

1.3.1.1 古代图书的序化组织 5

1.3.1.2 近现代传统文献的序化组织 5

1.3.1.3 技术驱动的序化组织 10

1.3.2 信息的检索利用 11

1.3.2.1 实体资源的检索利用 11

1.3.2.2 数字信息的检索利用 12

1.4 现代信息检索的主要内容 14

1.4.1 研究对象 14

1.4.2 任务目标 15

1.4.3 工作流程 16

1.4.4 设计难点 17

1.5 读者指南 18

思考与练习 18

第二章 二值向量表示与布尔检索 **21**

2.1 从词项文档关联矩阵到倒排索引 21

2.1.1 词项–文档关联矩阵 21

2.1.2 倒排索引：词项–文档关联矩阵的精简表示 22

2.2 词典组织 25

2.2.1 排序数组 25

2.2.2 哈希加链表 26

2.2.3 树形组织方式 27

2.3 常规布尔检索及其优化 29

2.3.1 布尔检索的常规方法 29

2.3.1.1 逻辑“与”检索 29

2.3.1.2 逻辑“或”检索 30

2.3.1.3 逻辑“非”检索 . . . 30
2.3.2 布尔检索的速度优化 . . . 30
2.3.2.1 优化表达式运算顺序 . . . 31
2.3.2.2 利用跳表加快合并 . . . 32
2.4 高级布尔检索 . . . 33
2.4.1 短语检索 . . . 33
2.4.1.1 双词索引 . . . 34
2.4.1.2 位置索引 . . . 34
2.4.1.3 短语索引 . . . 35
2.4.1.4 混合方法 . . . 35
2.4.2 通配检索 . . . 36
2.4.2.1 轮排索引 . . . 37
2.4.2.2 *k-gram* 索引 . . . 38
2.5 索引处理流程 . . . 38
2.5.1 从待索引对象到倒排索引的整体流程 . . . 39
2.5.2 文件解析——获取待索引的文本 . . . 39
2.5.3 词符切分——将文本切分为词符序列 . . . 40
2.5.4 语言分析——将词符规范化为词项 . . . 41
2.6 布尔检索模型及其特点 . . . 43
思考与练习 . . . 43

第三章 加权向量表示与排序式检索 45
3.1 向量空间模型 . . . 45
3.1.1 文档的加权向量表示 . . . 46
3.1.2 权重计算：词频与逆文档频率 . . . 46
3.1.3 相似度计算 . . . 48
3.2 概率检索模型 . . . 50
3.2.1 概率检索模型的基本假设 . . . 50
3.2.2 BIM 二值独立模型 . . . 51
3.2.3 BM25 模型 . . . 55
3.3 基于统计语言模型的检索模型 . . . 58
3.3.1 统计语言模型 . . . 58
3.3.2 查询似然模型 . . . 59
3.4 查询处理中的索引遍历 . . . 61
3.4.1 一次一词项方式 . . . 61
3.4.2 一次一文档方式 . . . 61
3.5 快速评分计算与排序 . . . 62
3.5.1 精确 Top K 计算与排序 . . . 62
3.5.1.1 单词项查询加速与堆排序 . . . 63
3.5.1.2 WAND 算法 . . . 63
3.5.2 非精确 Top K 计算与排序 . . . 65

3.5.2.1 索引去除 . . . 65
3.5.2.2 索引分层 . . . 65
3.5.2.3 簇剪枝 . . . 67
思考与练习 . . . 68

第四章 嵌入表示与向量检索 69
4.1 词嵌入 . . . 69
4.1.1 整数索引、独热编码与词嵌入表示 . . . 69
4.1.2 静态词嵌入 . . . 71
4.1.2.1 Word2Vec . . . 71
4.1.2.2 GloVe . . . 75
4.1.2.3 词向量的特点与用途 . . . 78
4.1.3 动态词嵌入 . . . 79
4.1.3.1 引入动态词嵌入的原因 . . . 79
4.1.3.2 BERT 动态词嵌入的学习方法 . . . 80
4.2 文本嵌入表示 . . . 82
4.2.1 Doc2Vec . . . 82
4.2.2 基于 Transformer 网络架构的文本嵌入 . . . 83
4.2.2.1 双编码器 . . . 84
4.2.2.2 交叉编码器 . . . 87
4.2.2.3 延迟交互编码器 . . . 89
4.3 图像嵌入与基于内容的图像检索 . . . 91
4.4 多模态嵌入与跨模态检索 . . . 94
4.5 向量近似近邻检索 . . . 96
4.5.1 基于树的 ANN 检索 . . . 97
4.5.1.1 kd-树的构建 . . . 97
4.5.1.2 kd-树的检索 . . . 98
4.5.1.3 kd-树的特点与改进 . . . 100
4.5.1.4 Annoy 算法 . . . 101
4.5.2 基于哈希的 ANN 检索 . . . 102
4.5.3 基于量化的 ANN 检索 . . . 102
4.5.3.1 乘积量化 PQ . . . 103
4.5.3.2 倒排文件 IVF 与 PQ 的结合：IVFPQ . . . 105
4.5.3.3 ScaNN：一种可扩展近邻算法 . . . 106
4.5.4 基于图的 ANN 检索 . . . 108
4.5.4.1 概率型跳表结构 . . . 108
4.5.4.2 NSW：导航小世界图 . . . 109
4.5.4.3 HNSW：层次化导航小世界图 . . . 110
4.5.5 ANN 检索工具包 . . . 111
思考与练习 . . . 112